

基于Densenet的单张图片天气预测系统

1711373 史恩扬¹

1711374 史浩森¹

Abstract

随着更多的天气图片数据开源，当面对精度要求不高的天气监测任务，过去通过温度，湿度，风力，紫外线强度等传感器获取天气参数进而进行天气探测方式过于繁琐，同时对机器设计也提出了更高的要求。针对此问题，我们计划实现更实时，方便的方式完成此问题。

本文实现了基于单张图片的实时天气分类系统。为了训练我们的网络，我们选择了*Image2Weather* [3]，其涵盖了多种天气类型。利用卷积神经网络对于天气图片进行天气特征的提取，并分类。完成的网络可以在短时间内快速的对于图片进行分类，正确率相较于过去的基于相同数据集图片的天气分类方法有所提升，相较于基于分类较为单调的分类器，本方法对于结果的划分更为准确和精细。

1. 引言

随着智能机器人应用的普及，对于其工作环境的实时监测愈加重要。先前的大部分方法是通过通讯获得所处位置的天气信息，或是装配各类传感器来达到实时环境监测。随着对于机器人面对突变的实时天气的要求以及对于其体积的要求提高，对更加高效，简洁，实时的天气预测系统的需求正在提升。对于在特殊环境作业的机器而言，通过通讯获取信息无疑对通信的稳定提出了要求，但一方面，对于部分天气恶劣的地区，通讯是无法保障的，另一方面，在某些相对独立的空间内，区域天气预报的意义并不大。因此我们尝试寻找空间精度更高，要求更低，实时性更优的天气监测方法。

相机作为大部分机器上配备的装置，保证了图片

获取对于机器的可行性以及实时性，同时对于机器设计或体积有所限制的机器人也更加友好。并且参考人类对于天气的感知途径，视觉占了很大一部分，例如，亮度较高的场景可能是晴天，能见度较低的场景可能是雾天，空中出现大量白色像素的场景则可能是雪天。这反映了图片与天气的联系，保证了从图片判断天气的可行性。

我们决定利用卷积神经网络，对于大量已标记天气的室外照片进行无监督学习，尝试提取天气特征并进行分类。为了在有限算力情况下，使得网络学习效果更优，我们选取Densenet169 [6]作为图片特征提取网络，并将所得特征输入一个wide-size浅层神经网络，输出即为对于各类天气的预测值。

2. 相关工作

本文主要关注基于室外图像的天气分类相关的相关文献。在这方面已经有许多研究，包括LLC [16]，ScSPM [18]这些传统图像分类方法，但是因为过于依赖图像结构以及忽视拍摄时的光线条件，因此准确率甚至比随机猜测更低，在利用SVM，Adaboost等方法优化后的效果仍不理想。

天空做为天气识别的重要区域，Cewu Lu和Chi-Keung Tang [14]提出首先要对图片中的天空区域进行检测，并且对于阴影，反光，对比度以及雾这些对于天气分类意义重大的要素进行检测，最终对于这些要素进行协同学习。但是，该方法对于天气图片的要求过高，当图片中缺少部分要素时，分类效果并不准确，在对于天气的二分任务上(区分晴天和多云两类天气)，此模型正确率仅达到53%。

Bor-Chun Chen和Pallabi Ghosh [2]利用ResNet-50 [5]，对于图片的天气情况进行较为复杂的分类（包括晴，雨，雪，多云四种天气），成功将准确率提升到

了65%左右,如果进一步利用AlexNet [10]探测到的日照角度,温度,湿度等天气要素可将准确率进一步提升到76%左右。但是对于其余因素的分析无疑加大了网络的训练任务,并且因为ResNet网络结构本身存在各层特征映射的冗余,因此该方法存在进一步提升的空间。

3. Image2Weather数据集

目前较大的开源天气数据集包括Flicker, SUN Dataset [1], Labelme Dataset [17], Webcam Clipart Datasets [11], AMOS [8]以及Image2Weather [3]。

4. 基于卷积神经网络的天气分类网络

4.1. 基于Densenet的特征提取网络

在深度学习网络中,随着网络深度的加深,梯度消失问题会愈加明显,目前很多论文都针对这个问题提出了解决方案,比如ResNet, Highway Networks, Stochastic depth, FractalNets等,尽管这些算法的网络结构有差别,但是核心都在于使用短链接层,将前几层的卷积结果直接传递到后面,使得梯度可以更好的传播。我们本次选取了目前比较先进的Densenet作为我们的特征提取网络。

Densenet的核心为其中的dense block,在传统的卷积神经网络中,如果存在L层,那么就会有L个连接,但是在DenseNet中,会有 $\frac{L(L+1)}{2}$ 个连接。简单讲,就是每一层的输入来自前面所有层的输出。从图[?]我们可以很容易的看出来Dense block的结构。

DenseNet的一个优点是网络更窄,参数更少,很大一部分原因得益于dense block的设计,这种连接方式使得特征和梯度的传递更加有效,网络也就更容易训练。而将浅层的特征不断直接传递给后面,提高了参数的重用率和更有利于梯度的直接传播。dense block的核心公式为 $x_l = H_l([x_0, x_1, \dots, x_{l-1}])$,区别于ResNet使用的直接相加, $x_l = H_l(x_{l-1}) + x_{l-1}$,同时这造成了DenseNet使用了concat的方式,这样造成了对于内存的使用过多。不过作者给我们提供了减少内存使用的实现版本和具体减少内存使用的思路[15]。

在一些图像分割和物体检测的任务上,基于DenseNet的模型往往可以省略在ImageNet上的预训练,直接从随机初始化的模型开始训练,最终达到相




图 1. Dense Block,来自论文原文

同甚至更好的效果。

在图像语义分割任务上,CVPR 2017的一篇workshop文章《The One Hundred Layers Tiramisu: Fully Convolutional DenseNets for Semantic Segmentation》[9]表明,基于DenseNet的全卷积网络(FCN)模型在不需要预训练的情况下甚至可以达到比其他预训练方法更高的精度,并且比达到相同效果的其他方法的模型要小10倍。

在本次任务中我们使用了DenseNet169的预训练版本作为我们的特征提取网络。

4.2. 浅层天气分类网络

在获得DenseNet的提取特征以后,我们使用一个四层的全连接网络作为我们的分类器,为了使得我们的分类效果更好,更容易拟合函数,我们这里使用了比较宽的网络,层与层之间使用了BatchNormalize(BN)[7]的归一化层,BN是由Google于2015年提出,这是一个神经网络训练的技巧,它不仅加快了模型的收敛速度,而且更重要的是在一定程度缓解了深层网络中“梯度弥散”的问题,从而使得训练深层网络模型更加容易和稳定。所以目前BN已经成为几乎所有卷积神经网络的标配技巧。并且我们这里并没有使用Dropout层,同时使用Dropout和BN可能会使得效果变差[12][13],和常用的L2正则化。

我们尝试了保留和不保留DenseNet最后一层分类的两个版本,实验证明最终获得了相似的结果。

5. 实验平台与环境

由于经费等客观原因的限制，GPU方面我们使用NVIDIA的GTX1060显卡进行模型的训练与预测，模型搭建使用了pytorch 1.0.2于windows10平台下运行，与训练的模型来自于torchvision库。

6. 实验结果及分析

由于硬件条件的限制，我们无法对Image2Weather [3]数据集中所有图像进行训练，故而我们选取数据集的40%作为数据集，并且对于所有数据进行随机修剪以及随机水平翻转。

将学习率设置为0.001，取75%数据集作为训练集，前50轮，网络输出与实际标签的损失值快速下降，在50轮之后损失值在0.1趋于平缓(见图 2)。

取25%数据作为测试集，从结果 3中可以看出,对于各类天气的预测准确率均远远高于随机分类的16.67%准确率，并且在云，晴两种较为普遍的天气类别表现良好。从表中可以发现，主要影响各类天气分类的主要类别为z-other类，通过对于数据集中的图像分析，我们发现该类别中包含在室内拍摄的图像，绝大部分均为物体的图像，有明显类别偏向的图像 4。因为这些图像的存在影响了网络的学习效果。另外，雨，雪天气常与雾天同时出现，并且雾天数据的缺少也造成了这些类别的效果不好，因此，将z-other类别去除，重新对模型进行训练，可以发现除了对于雨天的预测效果因为先前z-other类中包含大量类似于雨天和多云天气的图像，在去除后导致在对于此类类似的图像的分类过程中会出现误判以外，其他类的准确率均有所提升 5，总体准确率也提升至86.58%。通过对实验人员拍摄的天气特征明显的图片进行测试 6，效果较为理想。

另外，我们对于数据集的各类别进行进一步分析发现各个类别的图片数量分配不均，因此我们对于各类天气图像随机抽取350张，分别模型再次进行训练，发现损失值快速收敛 8。并且我们对浅层天气分类网络规模不同的模型在保证数据集平衡的前提下进行训练发现，当浅层天气分类网络规模较大时，损失值的收敛速度更快 9。




图 2. learning rate=0.001，对于训练集的损失值收敛于0.1

	Cloudy	Foggy	Rain	Snow	Sunny	Z-other
Cloudy	67.79	0.09	0.19	0.12	14.40	17.41
Foggy	11.48	42.58	0.00	0.56	7.28	38.10
Rain	20.31	0.292	33.52	0.22	9.42	36.23
Snow	6.31	0.16	0.16	48.48	10.78	34.11
Sunny	6.88	0.02	0.06	0.06	81.18	11.81
Z-other	10.08	0.07	0.16	0.20	15.46	74.00

图 3. 从结果而言，本网络对于多云以及晴天的分类有着良好的效果，其余类别因为z-other类，以及类别相似的原因，准确率偏低




图 4. 如图所示，z-other类中包含许多缺少天气元素，难以标记，或是错误标记的图像

7. 总结与展望

我们希望通过网络获取更多其他类别的天气图像数据，从之前的实验结果可以发现，数据集的不平衡以及类别分类不合理是导致实验结果不理想的很大的一个原因。因此，我们计划在之后通过爬虫的方式获取更多雾，雨，雪的天气图片，在保证数据集平衡点

	Cloudy	Foggy	Rain	Snow	Sunny
Cloudy	77.61	0.30	0.50	0.32	21.27
Foggy	6.00	91.43	0.00	0.28	2.29
Rain	51.23	0.74	21.57	1.96	24.51
Snow	28.00	1.07	1.87	40.27	28.80
Sunny	16.62	0.01	0.20	0.21	82.87

图 5. 将z-other类去除后，取剩余数据集的40%重新对模型进行训练结果




图 6. 对于天气特征明显的图像分类效果较为理想

Number of sunny images	70,501
Number of cloudy images	45,662
Number of snowy images	1,252
Number of rainy images	1,369
Number of foggy images	357
Number of other images	64,657
Total	183,798

图 7. 雪天，雨天以及雾天图像的总和仅占总数据量的1.62%，这也导致模型对于雨天，雪天，雾天的分类可能会欠拟合

前提下，进一步扩充数据集，从之前的实验结果，我们有理由相信模型分类准确率将进一步提升。

结合实际情况，我们计划将分类为雾的图片利用Kaiming He和Xiaoou Tang提出的暗通道优先的图像去雾算法 [4]进行处理，为了机器基于图像的下一步探测，识别等操作提供相对较好的图像数据。

参考文献

[1] B. C. Russell, A. Torralba, K. Murphy, and W. T. Freeman. Labelme: A database and web-based tool for image annotation. *International Journal of Computer*




图 8. 当数据集中各类别的数据量相对平衡时，模型在训练过程中的收敛速度明显增快，在20轮左右即可达到较为令人满意的结果




图 9. 当浅层天气分类网络的规模更大时，模型在训练过程中的收敛速度有所提升

Vision, 77, 05 2008. 2

[2] B.-C. Chen, P. Ghosh, V. I. Morariu, and L. Davis. Detection of metadata tampering through discrepancy between image content and metadata using multi-task deep learning. pages 1872–1880, 07 2017. 1

[3] W.-T. Chu, X.-Y. Zheng, and D.-S. Ding. Image2weather: A large-scale image dataset for weather property estimation. pages 137–144, 04 2016. 1, 2, 3

[4] K. He, J. Sun, and X. Tang. Single image haze removal using dark channel prior. *IEEE Trans. Pattern Anal. Mach. Intell.*, 33:2341–2353, 01 2011. 4

- [5] K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. pages 770–778, 06 2016. [1](#)
- [6] G. Huang, Z. Liu, and K. Weinberger. Densely connected convolutional networks. page 12, 08 2016. [1](#)
- [7] S. Ioffe and C. Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift, 2015. [2](#)
- [8] N. Jacobs, N. Roman, and R. Pless. Consistent temporal variations in many outdoor scenes. 06 2007. [2](#)
- [9] S. Jégou, M. Drozdal, D. Vazquez, A. Romero, and Y. Bengio. The one hundred layers tiramisu: Fully convolutional densenets for semantic segmentation, 2016. [2](#)
- [10] A. Krizhevsky, I. Sutskever, and G. E. Hinton. Imagenet classification with deep convolutional neural networks. *Neural Information Processing Systems*, 25, 01 2012. [2](#)
- [11] J.-F. Lalonde, A. Efros, and S. G. Narasimhan. Web-cam clip art: Appearance and illuminant transfer from time-lapse sequences. *ACM Trans. Graph.*, 28, 12 2009. [2](#)
- [12] H. Li, W. Ouyang, and X. Wang. Multi-bias non-linear activation in deep neural networks, 2016. [2](#)
- [13] X. Li, S. Chen, X. Hu, and J. Yang. Understanding the disharmony between dropout and batch normalization by variance shift, 2018. [2](#)
- [14] C. Lu, D. Lin, J. Jia, and C.-K. Tang. Two-class weather classification. pages 3718–3725, 06 2014. [1](#)
- [15] G. Pleiss, D. Chen, G. Huang, T. Li, L. van der Maaten, and K. Q. Weinberger. Memory-efficient implementation of densenets, 2017. [2](#)
- [16] J. Wang, J. Yang, K. Yu, F. Lv, T. S. Huang, and Y. Gong. Locality-constrained linear coding for image classification. pages 3360–3367, 06 2010. [1](#)
- [17] J. Xiao, J. Hays, K. Ehinger, A. Oliva, and A. Torralba. Sun database: Large-scale scene recognition from abbey to zoo. pages 3485–3492, 06 2010. [2](#)
- [18] J. Yang, K. Yu, Y. Gong, and T. S. Huang. Linear spatial pyramid matching using sparse coding for image classification. pages 1794–1801, 06 2009. [1](#)